FLOWViZ

Framework for phylogenetic processing

Miguel Luís ^{1,2} e Cátia Vaz ^{1,2}

¹ INESC-ID Lisboa

² Instituto Superior de Engenharia de Lisboa, Instituto Politécnico de Lisboa

Contexto

A Filogenia é o estudo da evolução entre grupos de organismos e das suas caraterísticas.

Figura 1 - Um exemplo de uma árvore filogenética. **Fonte:** https://www.researchgate.net/figure/

Phylogeny-of-major-groups-of-land-pla nts-Based-on-13151920-Approximatenumbers-of_fig1_267043482

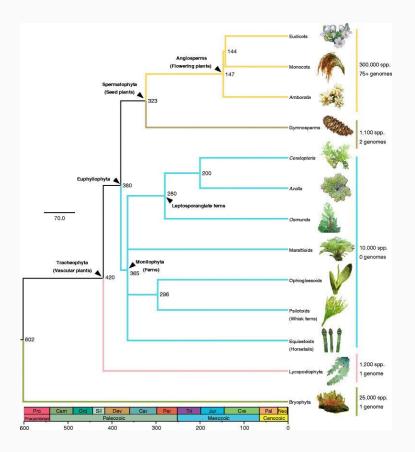


Figura 1

Análise filogenética

- Processos complexos, compostos por vários passos ou tarefas;
- Fluxogramas, denominados por workflows ou work pipelines;
- Vários inputs/outputs por passo ou tarefa;

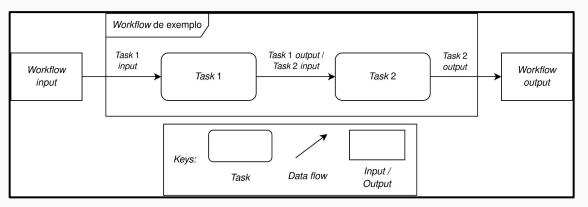


Figura 2 - Estrutura geral de um workflow

Ferramentas filogenéticas existentes

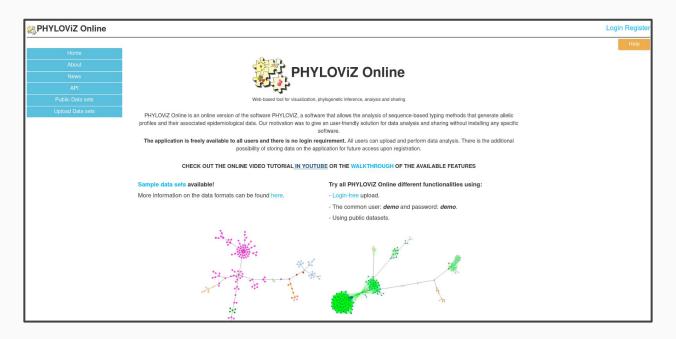


Figura 3 - Página principal da ferramenta filogenética *PHYLOViZ*.

Fonte: phyloviz.net

Problema

- Processos podem demorar horas ou dias;
- Processos que envolvem grandes quantidades de informação;
- Configuração manual de workflows.

Problema

Figura 4 - Exemplo de um workflow complexo. Fonte: https://www.researchgate.net/fig ure/A-compl ex-DAG-structure fig4 7885204

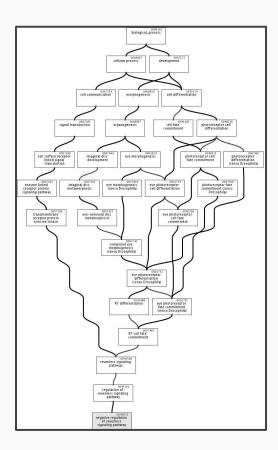


Figura 4

Sistemas de workflow

- Fornecem uma linguagem própria para construir workflows -Domain-Specific Language (DSL);
- Permitem automatizar processos;
- Recorrem a computação distribuída para executar workflows e permitir escalabilidade de recursos;
- Problema: Várias soluções existentes, mas pouca integração entre sistemas de workflow e ferramentas filogenéticas.

Ferramenta filogenética que integrou um sistema de workflow



Figura 5.1 - Página principal da ferramenta *NGPhylogeny* **Fonte:** ngphylogeny.fr

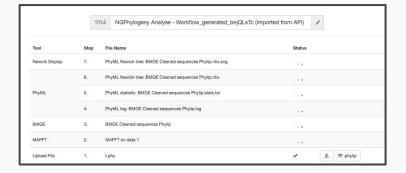


Figura 5.2 - Lista de tarefas num workflow **Fonte:** ngphylogeny.fr

FLOWVIZ

- Uma framework que integra ferramentas filogenéticas com o sistema de workflow - Apache Airflow;
- A integração de ferramentas, que correspondem aos passos de execução de um workflow, é feita a partir de contratos;
- Permite aos utilizadores adicionarem ferramentas filogenéticas e executarem workflows com as mesmas.

Contratos

- Especificação de regras entre entidades;
- Relações de natureza *loosely-coupled*:
 - Adaptabilidade;
 - Flexibilidade.

Arquitetura

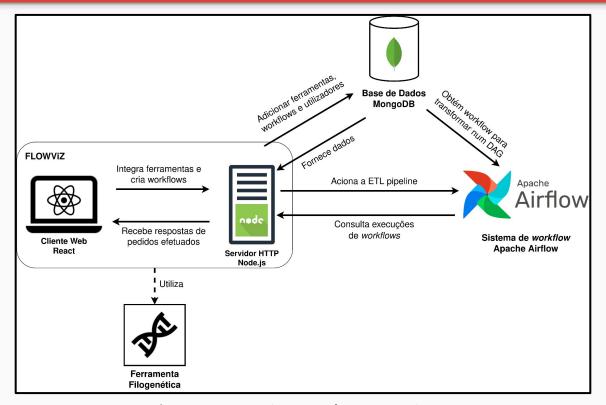


Figura 6 - Arquitetura do FLOWViZ e integração com ferramenta filogenética

Caso de uso - adicionar ferramenta

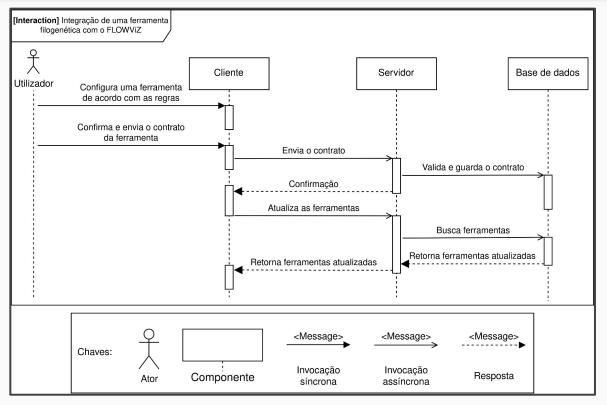


Figura 7 - Diagrama de interação: integrar uma ferramenta filogenética

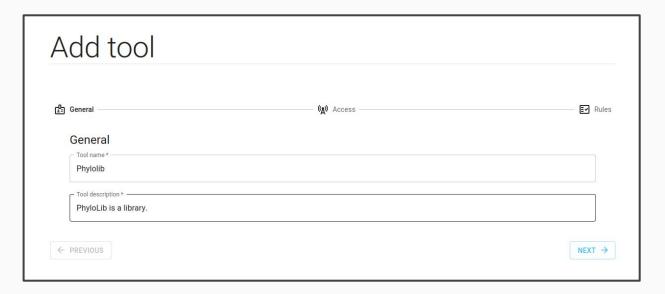


Figura 8 - Adicionar ferramenta - informação geral

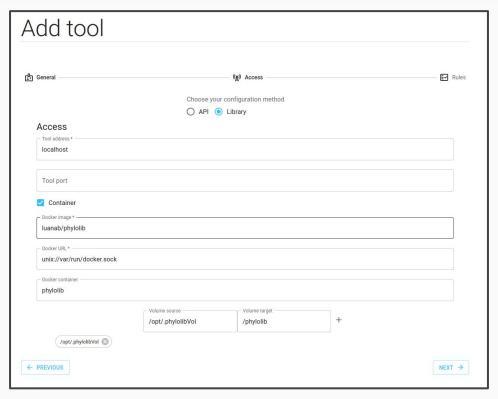


Figura 9 - Adicionar ferramenta - informação de acesso à ferramenta

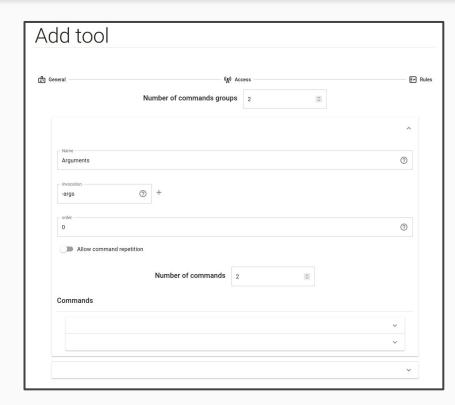


Figura 10.1 - Adicionar ferramenta - Especificação de grupos de comandos

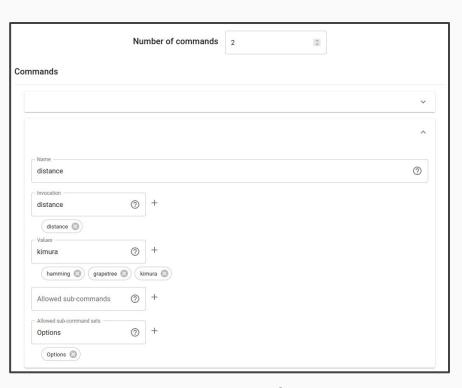


Figura 10.2 - Adicionar ferramenta - Especificação de um comando



Figura 11 - Documentação da ferramenta adicionada.

Caso de uso - construção e execução de um workflow

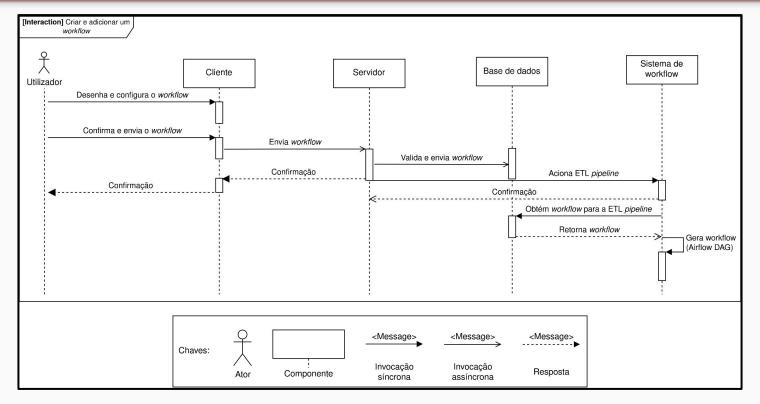


Figura 12 - Diagrama de interação: criar e adicionar um *workflow*

Demonstração aplicacional - construção e execução de um workflow

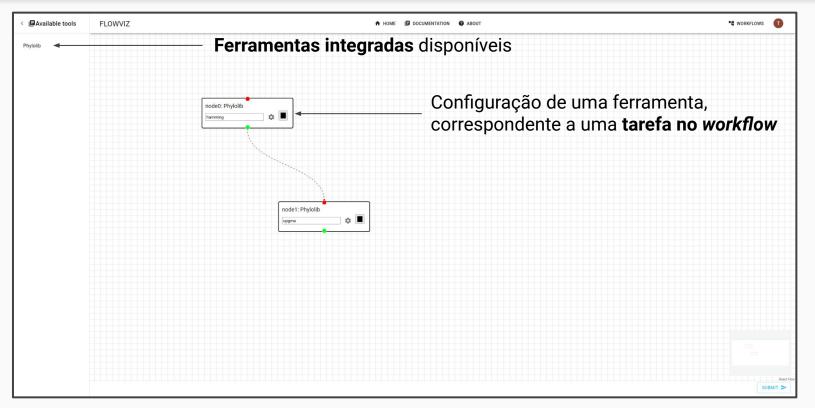


Figura 13 - Whiteboard - Desenho e criação de workflows

Demonstração aplicacional - construção e execução de um workflow

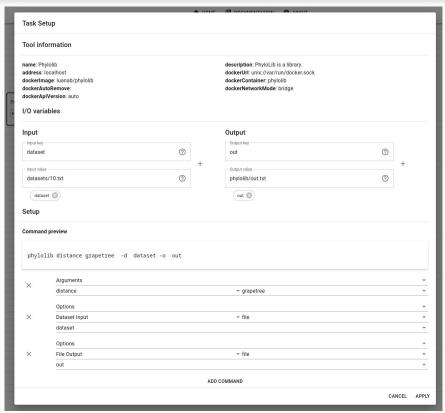


Figura 14 - Configuração individual de uma tarefa do *workflow*

Demonstração aplicacional - construção e execução de um workflow

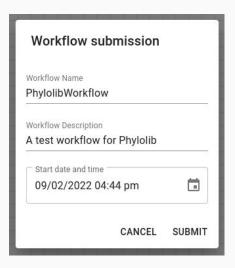


Figura 15 - Configuração de informação geral do *workflow* (submissão)

Apache Airflow - Construção dinâmica de DAGs

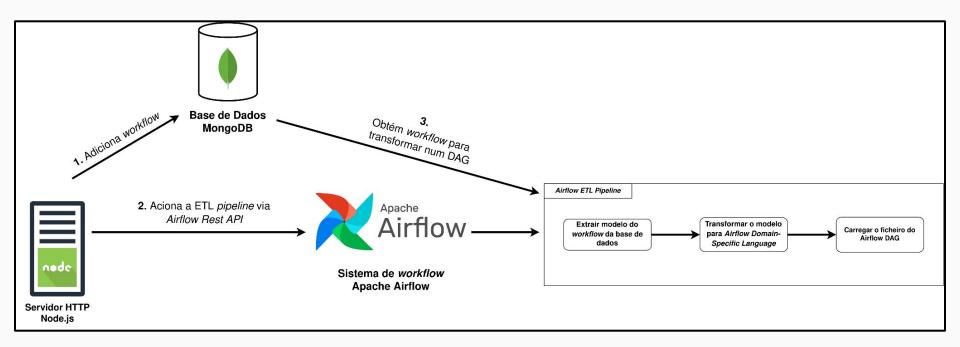


Figura 16 - Fluxo da construção dinâmica de um *Airflow* DAG

Apache Airflow - Construção dinâmica de DAGs

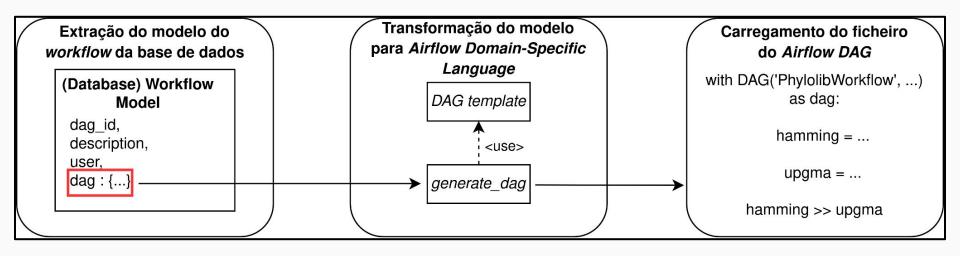


Figura 17 - Detalhe da *ETL pipeline*, desempenhado pelo DAG *dag_generator.py*

Caso de uso - obtenção de resultados

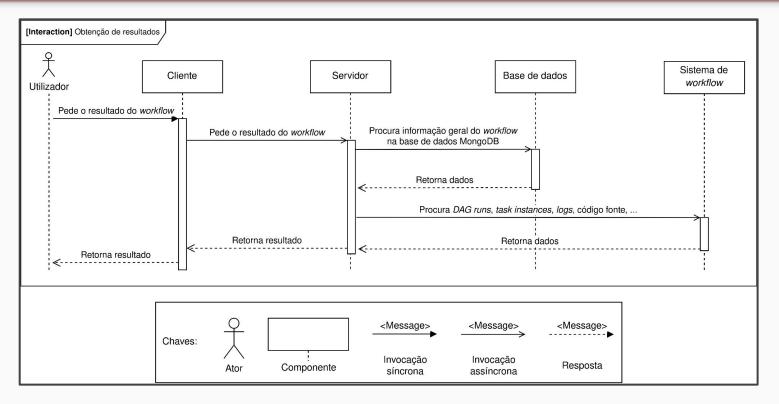
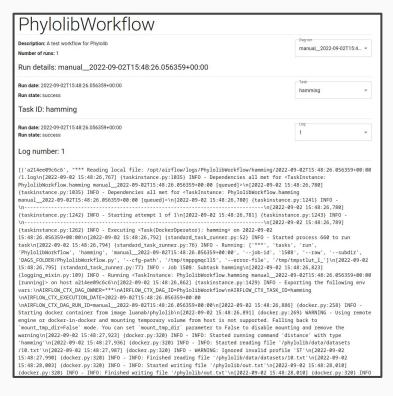


Figura 18 - Diagrama de interação: Obtenção de resultados

Demonstração aplicacional - Detalhe de um workflow do utilizador



```
Airflow script
from airflow import DAG
from datetime import datetime
from airflow.providers.docker.operators.docker import DockerOperator
from docker.types import Mount
default args = {
    'owner'
                            : 'airflow'.
    'description'
                            : 'A test workflow for Phylolib',
                            : datetime.today(),
    'start_date'
with DAG('PhylolibWorkflow', schedule_interval=None, default_args=default_args) as dag:
        hamming = DockerOperator(task id = 'hamming',
               image = 'luanab/phylolib',
               api version = 'auto'.
                mounts = [Mount(target='/phylolib', source='/opt/.phylolibVol', type='bind')],
               command = 'distance hamming --dataset=ml:/phylolib/data/datasets/10.txt --out=symmetric:/phylolib/out.txt',
                auto remove = 'true',
               docker_url = 'unix://var/run/docker.sock',
               network mode = 'bridge',)
        upgma = DockerOperator(task_id = 'upgma',
               image = 'luanab/phylolib',
                api_version = 'auto',
                mounts = [Mount(target='/phylolib', source='/opt/.phylolibVol', type='bind')],
               command = 'algorithm upgma --out=newick:/phylolib/tree.txt --matrix=symmetric:/phylolib/out.txt',
                auto_remove = 'true',
                docker url = 'unix://var/run/docker.sock',
               network mode = 'bridge',)
hamming >> upgma
```

Figura 19.1 - *Log* da execução do *workflow* submetido

Figura 19.2 - Código fonte do DAG, dinamicamente gerado no Apache Airflow

Obrigado